Спринт 2

Тема: Аналитические веб-сервисы

В рамках данного спринта ведется отработка следующих навыков:

- Подключение к произвольному внешнему веб-сервису по REST API / SOAP и парсинг ответа из него с целью последующего использования в обработке данных.
- Создание и публикация собственного аналитического веб-сервиса, в том числе с вызовом внутри ML-модели.

Теоретическая база

Понятие, типы и архитектура веб-сервисов. Веб-стандарты. Характеристики веб-сервисов. Преимущества и недостатки. Этапы развития веб-сервисов. Первые средства создания веб-сервисов. Современное распространение технологии. XML. Структура XML-документа. Правила задания имен. JSON. Структура JSON-документа. Правила задания ключей и значений. Сравнение XML и JSON. SOAP. Структура SOAP-сообщения. WSDL. Структурная схема WSDL. REST. REST-запросы. Описание REST-сервиса. Сравнение SOAP/WSDL и REST.

Программное обеспечение

1. Python, VS Code (или другая IDE) с плагинами:
    a. GigaCode
    b. Continue (опционально)
2. Облачная среда Google Colab, плагин Jupiter.
3. Ollama для запуска локальных LLM-моделей (опционально).

Все практические задачи выкладывать в свой проект на gitlab/github/gitverse.

Важные замечания.

1. При выполнении всех работ допускается использовать AI-ассистента.
2. В комментариях к коду (блоки markdown) необходимо отразить, какой AI-ассистент использовался.

Практическая работа №2. Подключение к внешнему веб-сервису

Материалы для выполнения работы и задание расположено здесь:

https://github.com/amalrik1/develop_ml_course/tree/main/practice1

Порядок выполнения: подключаемся к внешнему веб-сервису из Python, вызываем методы, парсим json, при необходимости проводим постобработку.

ВАРИАНТЫ ЗАДАНИЙ

Задания для DaData API (требует бесплатной регистрации – до 10 000 запросов/день)

Документация: https://dadata.ru/api/

Регистрация: https://dadata.ru/profile/

1. Подсказки по адресам
   Метод: https://suggestions.dadata.ru/suggestions/api/4_1/rs/suggest/address
   Документация: https://dadata.ru/api/suggest/address/
   Задание: по запросу «Москва Тверская» вывести первые 3 полных адреса.
2. Подсказки по ФИО
   Метод: https://suggestions.dadata.ru/suggestions/api/4_1/rs/suggest/name
   Документация метода: https://dadata.ru/api/suggest/name/
   Задание: написать функцию, которая по введенному имени «Алекс» найдет все варианты полных ФИО и определит пол для каждого варианта.

3. Поиск организаций по названию
   Метод: https://suggestions.dadata.ru/suggestions/api/4_1/rs/suggest/party
   Документация метода: https://dadata.ru/api/suggest/party/
   Задание: найти все организации со словом «Сбербанк» в названии. Для каждой найденной организации вывести: полное название, ИНН, адрес, статус (действующая/ликвидированная), ФИО руководителя.

4. Детальная информация об организации по ИНН
   Сайт: https://suggestions.dadata.ru/suggestions/api/4_1/rs/findById/party
   Документация метода: https://dadata.ru/api/find-party/
   Задание: по ИНН «7707083893» получить максимально полную информацию об организации: уставный капитал, коды ОКВЭД, количество сотрудников, финансовые показатели, учредители. Создать структурированный отчет.

Задания для Яндекс Геокодер API (требует бесплатной регистрации – 1000 запросов/день)

Документация: https://yandex.ru/dev/geocode/doc/ru/
Регистрация: https://developer.tech.yandex.ru/
Получение ключа: https://developer.tech.yandex.ru/services/

5. Прямое геокодирование адресов
   Описание: Получение координат по адресу с учетом опечаток
   Метод: https://geocode-maps.yandex.ru/1.x/?apikey=KEY&geocode=ADDRESS&format=json
   Документация метода: https://yandex.ru/dev/geocode/doc/ru/request
   Примеры запросов: https://yandex.ru/dev/geocode/doc/ru/examples
   Задание: создать геокодер для адреса «Москва, Красная площадь, 1». Получить точные координаты, проверить обработку опечаток («Красая площадь"). Вывести широту, долготу и точность определения.

6. Обратное геокодирование координат
   Описание: Определение адреса по географическим координатам
   Метод: https://geocode-maps.yandex.ru/1.x/?apikey=KEY&geocode=LON,LAT&format=json
   Документация метода: https://yandex.ru/dev/geocode/doc/ru/request
   Параметры запроса: https://yandex.ru/dev/geocode/doc/ru/parameters
   Задание: по координатам (37.617635, 55.755814) определить точный адрес. Получить информацию о ближайших объектах: улице, доме, районе, метро. Создать функцию для массовой обработки координат.

7. Поиск объектов по типу
   Метод: https://geocode-maps.yandex.ru/1.x/?apikey=KEY&geocode=COORDS&kind=metro&format=json
   Документация метода: https://yandex.ru/dev/geocode/doc/ru/parameters
   Типы объектов: https://yandex.ru/dev/geocode/doc/ru/kind
   Задание: найти ближайшие 3 станции метро к координатам центра Москвы (37.6175, 55.7558). Для каждой станции вывести название, расстояние от исходной точки, линию метро (если доступно).

8. Геокодирование с ограничением области поиска
   Метод: https://geocode-maps.yandex.ru/1.x/?apikey=KEY&geocode=QUERY&ll=LON,LAT&spn=WIDTH,HEIGHT
   Документация метода: https://yandex.ru/dev/geocode/doc/ru/parameters
   Ограничение области: https://yandex.ru/dev/geocode/doc/ru/ll-spn
   Задание: найти все объекты «Парк» в пределах МКАД (центр: 37.6175,55.7558, область поиска: 0.5°×0.5°). Получить список парков с координатами и описанием каждого.

Задания для VK API (публичные методы без токена или с простой регистрацией приложения)

Документация: https://dev.vk.com/ru
Справочник методов: https://dev.vk.com/ru/method
Регистрация приложения: https://vk.com/apps?act=manage
Права доступа: https://dev.vk.com/ru/reference/access-rights

9. Получение информации о пользователе
   Метод: https://api.vk.com/method/users.get?user_ids=USER_ID&fields=city,bdate,sex,photo_200&v=5.131
   Документация метода: https://dev.vk.com/ru/method/users.get
   Поля пользователя: https://dev.vk.com/ru/reference/objects/user
   Задание: по ID любого пользователя (например, собственного ID) получить: имя, фамилию, город, дату рождения, пол, фото. Создать функцию для красивого вывода анкеты пользователя с обработкой приватных данных.
10. Анализ друзей пользователя (если профиль открыт)
    Метод: https://api.vk.com/method/friends.get?user_id=USER_ID&fields=city,bdate,sex&v=5.131
    Документация метода: https://dev.vk.com/ru/method/friends.get
    Поля друзей: https://dev.vk.com/ru/reference/objects/user
    Задание: получить список друзей пользователя и провести анализ: соотношение по полу, возрастные группы, топ-5 самых популярных городов среди друзей. Требует открытого списка друзей.

11. Информация о группах пользователя
    Метод: https://api.vk.com/method/groups.get?user_id=USER_ID&extended=1&fields=members_count,activity&v=5.131
    Документация метода: https://dev.vk.com/ru/method/groups.get
    Поля группы: https://dev.vk.com/ru/reference/objects/group
    Задание: Получить список групп пользователя (если доступен). Для каждой группы вывести: название, количество участников, тип активности, дату создания. Найти самые популярные группы по количеству участников.

12. Описание: Поиск пользователей ВКонтакте по имени и городу
    Метод: https://api.vk.com/method/users.search?q=Александр&city=1&count=10&fields=city,bdate,sex&v=5.131
    Документация метода: https://dev.vk.com/ru/method/users.search
    Задание:
    1. Выполнить запрос, чтобы получить до 10 пользователей с именем «Александр» из Москвы (city=1).
    2. Для каждого пользователя вывести: имя, фамилию, пол и дату рождения.
    3. Подсчитать, сколько из найденных пользователей младше 30 лет.

Практическая работа №3. Разработка собственного веб-сервиса

Материалы для выполнения работы и пример веб-сервиса на FLASK расположены здесь:

https://github.com/amalrik1/develop_ml_course/tree/main/practice2

Вам предстоит разработать, опубликовать и вызвать ***свой*** собственный веб-сервис с ML-моделью, используя только Python, и сделать это двумя способами:

1. На локальном компьютере с использованием библиотеки FLASK.
2. На Google Colab с применением библиотеки (localtunnel, ngrok и другие, см. список здесь).

Внимание! Сервис ngrok не доступен из РФ.

Для понимания, как устроен веб-сервис на Python, нужно понимать следующие темы:

- Виртуальные окружения Python и работа с venv (пример статьи)
- Проектирование RESTful API с помощью Python и Flask (пример статьи 1, пример статьи 2, пример статьи 3)
- Сериализация и десериализация объектов в Python (пример статьи).

Создание и разворачивание веб-сервиса на локальной машине зависит от выбранного способа, от операционной системы и других нюансов. Ниже приведен рекомендуемый путь (для ОС Windows и Python 3.x, НЕ Anaconda), но вы можете идти своим путем.

Создайте на диске отдельную папку и поместите в нее файлы согласно структуре, указанной на рисунке.

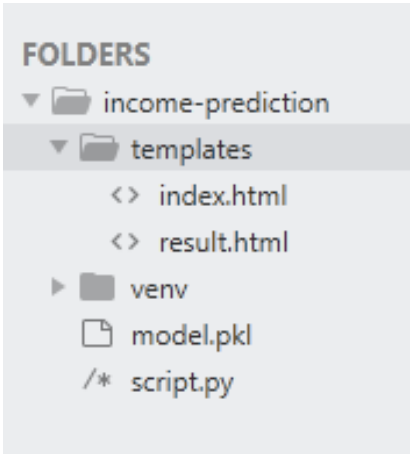

Папка venv появится после установки виртуальной среды Python в эту папку. Сделать это проще всего так:

1. Установите библиотеку virtualenv для Python командой

   ```
   pip install virtualenv
   ```

2. В командной строке перейдите в папку проекта и установите виртуальное окружение Python командой

```
virtualenv venv
```

Имя папки может быть любым.

3. Активируйте виртуальное окружение, запустив `activate.bat` из папки `Scripts`.
4. Установите все требуемые для работы сервиса библиотеки Python в виртуальное окружение.
5. Установите библиотеку flask.
6. Выполните команду FLASK_APP = script.py и запустите flask:

```
flask run
```

7. Откройте страницу http://127.0.0.1:5000 – там отобразится веб-форма со страницы index.html.
8. Заполните форму и нажмите Submit. Сервис должен успешно отработать и выдать результат, открыв страницу result.html.

Если этого не происходит – ищите, в чем проблема (в консоли отображаются сообщения об ошибках). Причин может быть много – от неверных команд (для Linux они другие), до несовместимости версий библиотек.

Разрешается отправлять в веб-сервис готовый json, или использовать специальные программы для тестирования запросов к веб-сервисам, например, Postman.

Крайне желательно сделать авторизацию к вашему веб-сервису по логину и паролю.

Следующий этап – это перенос вашего веб-сервиса в среду выполнения Google Colab. Как это сделать, можно почитать здесь и здесь. Остальное – на самостоятельную проработку и поиск источников.

Важно! Для выполнения работы у каждого студента должна быть своя ML-модель. Пока что можно взять любой учебный датасет: Ирисы Фишера, Титаник и другие с ресурса Kaggle/datasets, или вашу модель с практик на 1 курсе.