Спринт uplift

Тема: Модели прироста отклика

Задание:

1. Загрузить и изучить датасет
2. Провести EDA: проверить баланс групп, распределение признаков
3. Реализовать 2-3 подхода к uplift-моделированию (например: две модели, единая модель, деревья прироста)
4. Оценить качество моделей с помощью метрик: AUQC, Uplift@K, децильный анализ
5. Выделить сегменты клиентов: убеждаемые, уверенные, равнодушные, антагонисты
6. Откомментировать код

Библиотеки:

- CausalML или scikit-uplift
- pandas, numpy, matplotlib
- sklearn (для базовых моделей)

Рекомендуемые датасеты

1. X5 RetailHero Uplift Modeling Dataset

Описание: Датасет от российской компании X5 Retail Group (сети «Пятёрочка», «Перекрёсток»), предоставленный для исследования методов uplift-моделирования в ритейле.

Что включает:

- Обезличенные и агрегированные данные о поведении клиентов супермаркетов
- Данные о факте взаимодействия с клиентом (маркетинговые коммуникации)
- Факты совершения целевого действия после коммуникации
- Контрольная и целевая группы

Где скачать: через библиотеку scikit-uplift: from sklift.datasets import fetch_x5

Документация: https://uplift-modeling.com/

2. Criteo Uplift Prediction Dataset

Описание: Крупномасштабный датасет от французской рекламной компании Criteo, созданный из нескольких тестов инкрементальности в онлайн-рекламе.

Что включает:

- 25 миллионов строк (есть версия 10% для быстрого тестирования)
- 12 анонимизированных признаков (f0-f11)
- Treatment/control groups
- Две целевые переменные: визиты (visit) и конверсии (conversion)
- Exposure (факт показа рекламы)

Где скачать:

- Официальный сайт Criteo AI Lab: https://ailab.criteo.com/criteo-uplift-prediction-dataset/
- HuggingFace: https://huggingface.co/datasets/criteo/criteo-uplift
- Через scikit-uplift: from sklift.datasets import fetch_criteo

3. Hillstrom Email Marketing Dataset

Описание: Классический датасет от Kevin Hillstrom (MineThatData) для email-маркетинга с тремя группами воздействия.

Что включает:

- ~64,000 клиентов
- 3 группы: control, mens email, womens email
- Демографические данные
- История покупок
- Conversion и выручка как целевые переменные

Где скачать:

- Через scikit-uplift: from sklift.datasets import fetch_hillstrom
- Kaggle: поиск «Hillstrom»

4. Megafon Uplift Competition Dataset

Описание: Датасет от Мегафона для соревнования по uplift-моделированию в телекоммуникациях.

Что включает:

- Данные телекоммуникационной компании
- Клиентские признаки
- Treatment/control для маркетинговых кампаний

Где скачать:

- Через scikit-uplift: from sklift.datasets import fetch_megafon